Яндекс

Yandex Cup 2023 - ML: RecSys

1 место

Кадулин Виталий

План

Постановка задачи

Данные

Модели

Обучение

Построение ансамбля

Краткая история сабмитов

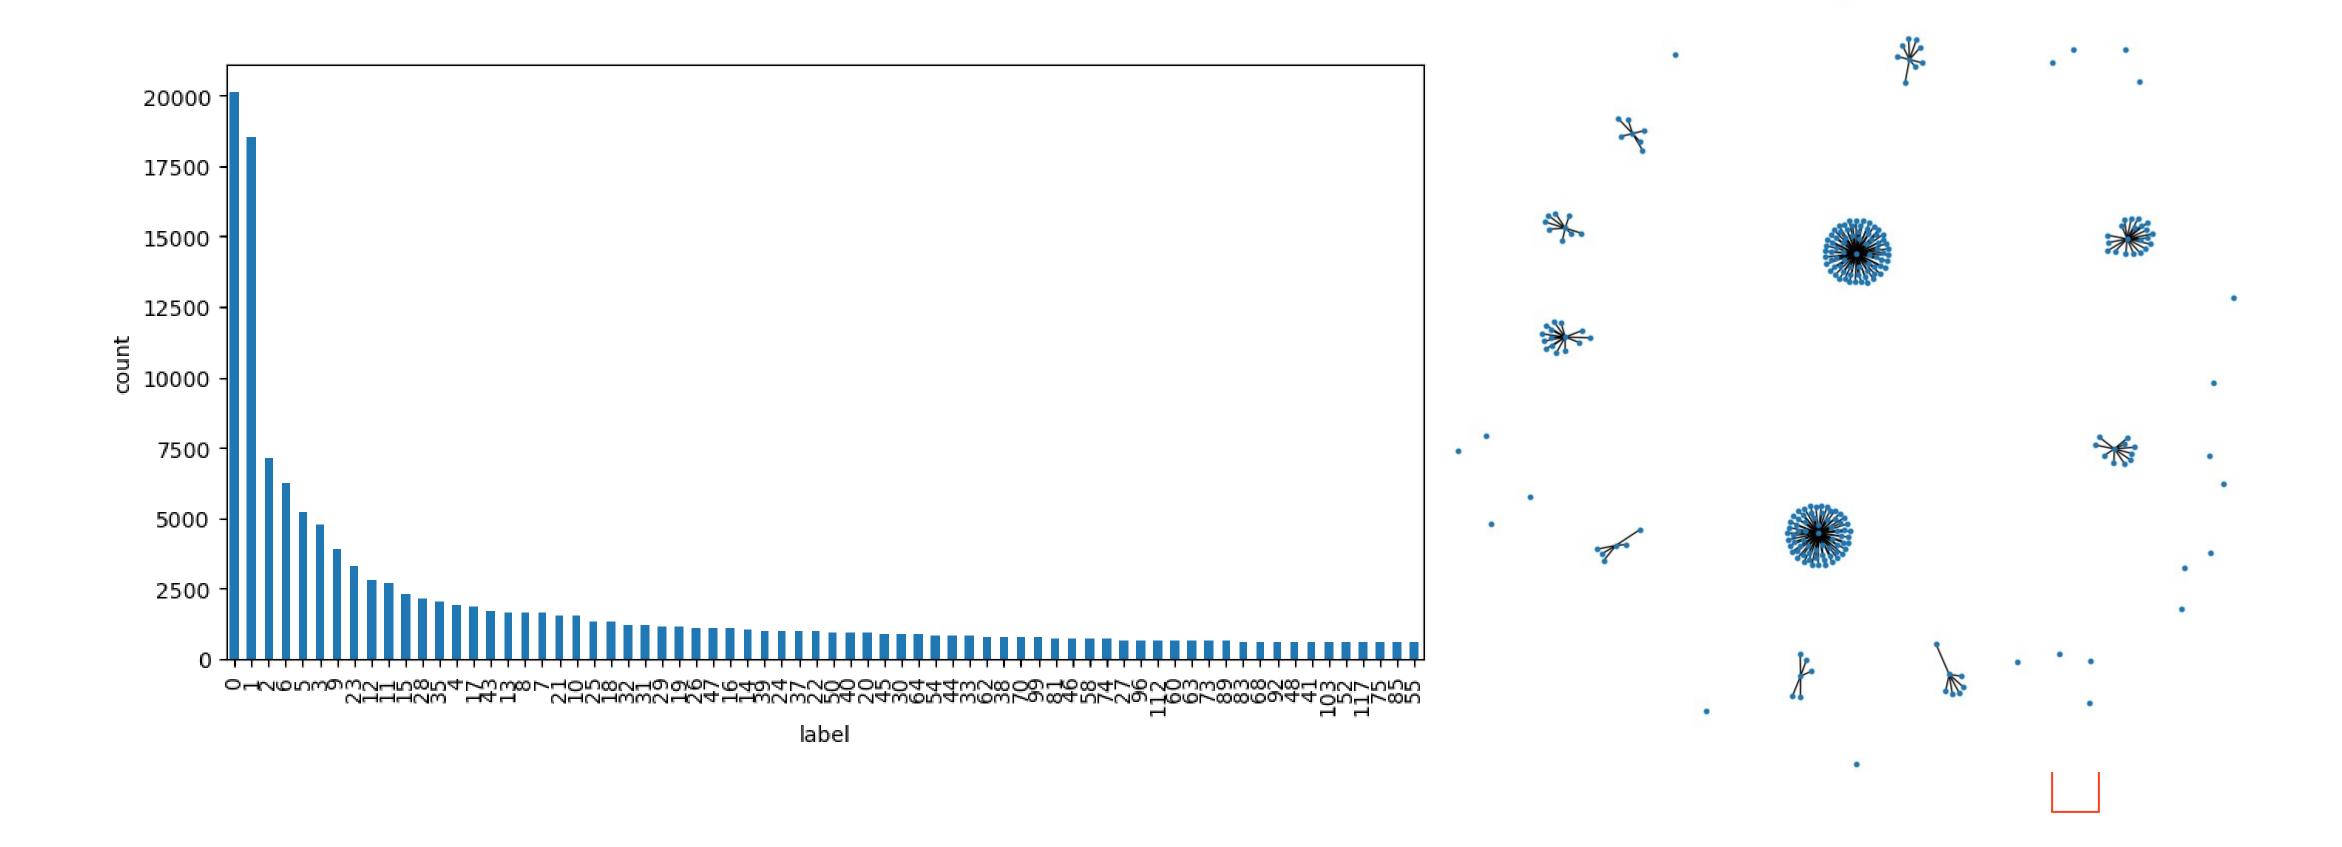
Пробовал, но не зашло

Постановка задачи

Требуется предсказать жанры музыкальных треков по эмбеддингам.

- multi-label классификация на 256 классов
- # треков в обучающей выборке 51134
- # пар (трек, лейбл) в обучающей выборке 201562
- метрика МАР тасго

Данные



Модели

family	# models	
conformer	11	
transformer	2	Relative embeddings; sliding window mask
resnet	3	1D, ECA
inception	2	1D

Обучение

- Optimizer AdamW
- LR ReduceLROnPlateau
- 3 / 10 пар (train, valid) из KFold(n_splits=10)
- Loss asymmetric focal loss

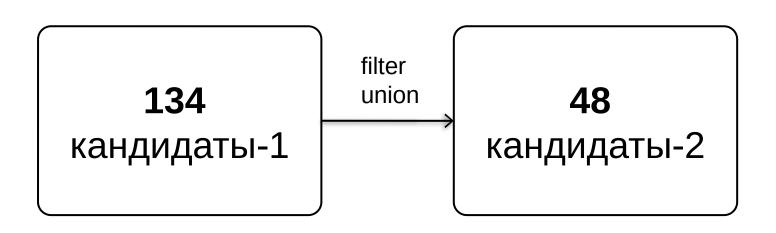
$$ASL = \begin{cases} L_{+} = (1-p)^{\gamma_{+}} \log(p) \\ L_{-} = (p_{m})^{\gamma_{-}} \log(1-p_{m}) \end{cases}$$
$$p_{m} = \max(p-m, 0)$$

Построение ансамбля

```
cand0 = set()
cand2 = set()
                                                                     10
                                                                                       189
                                                                              union
cand3 = set()
                                                                                    кандидаты-0
                                                                новые модели
                                                                                          filter
def filter1(candidates):
                                                                                       134
                                                                                    кандидаты-1
    return {x for x in candidates if map_score(x) > 0.25}
                                                                                          filter, union
while True:
                                                                                        48
                                                                                    кандидаты-2
    cand0 |= fit_new_models() # 1.
    cand1 = filter1(cand0) # 2.
                                                                                         filter, blend
    cand2 \mid = filter2(cand1) # 3.
                                                                                        18
                                                                                      сабмит
    cand3 |= filter3(cand2) # 4. ensure fold2
    submit = blend(cand3) # 5. ensure fold3
```

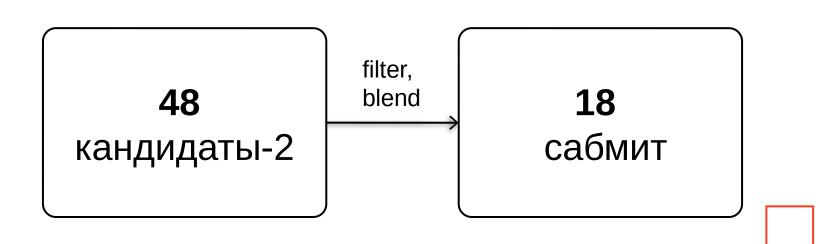
Построение ансамбля: шаг 3

method	# models	map
all	134	0.3109
top by logreg	61	0.3152
top-50 by valid map	50	0.3169
top-20 by num best	20	0.3172
greedy	30	0.3193

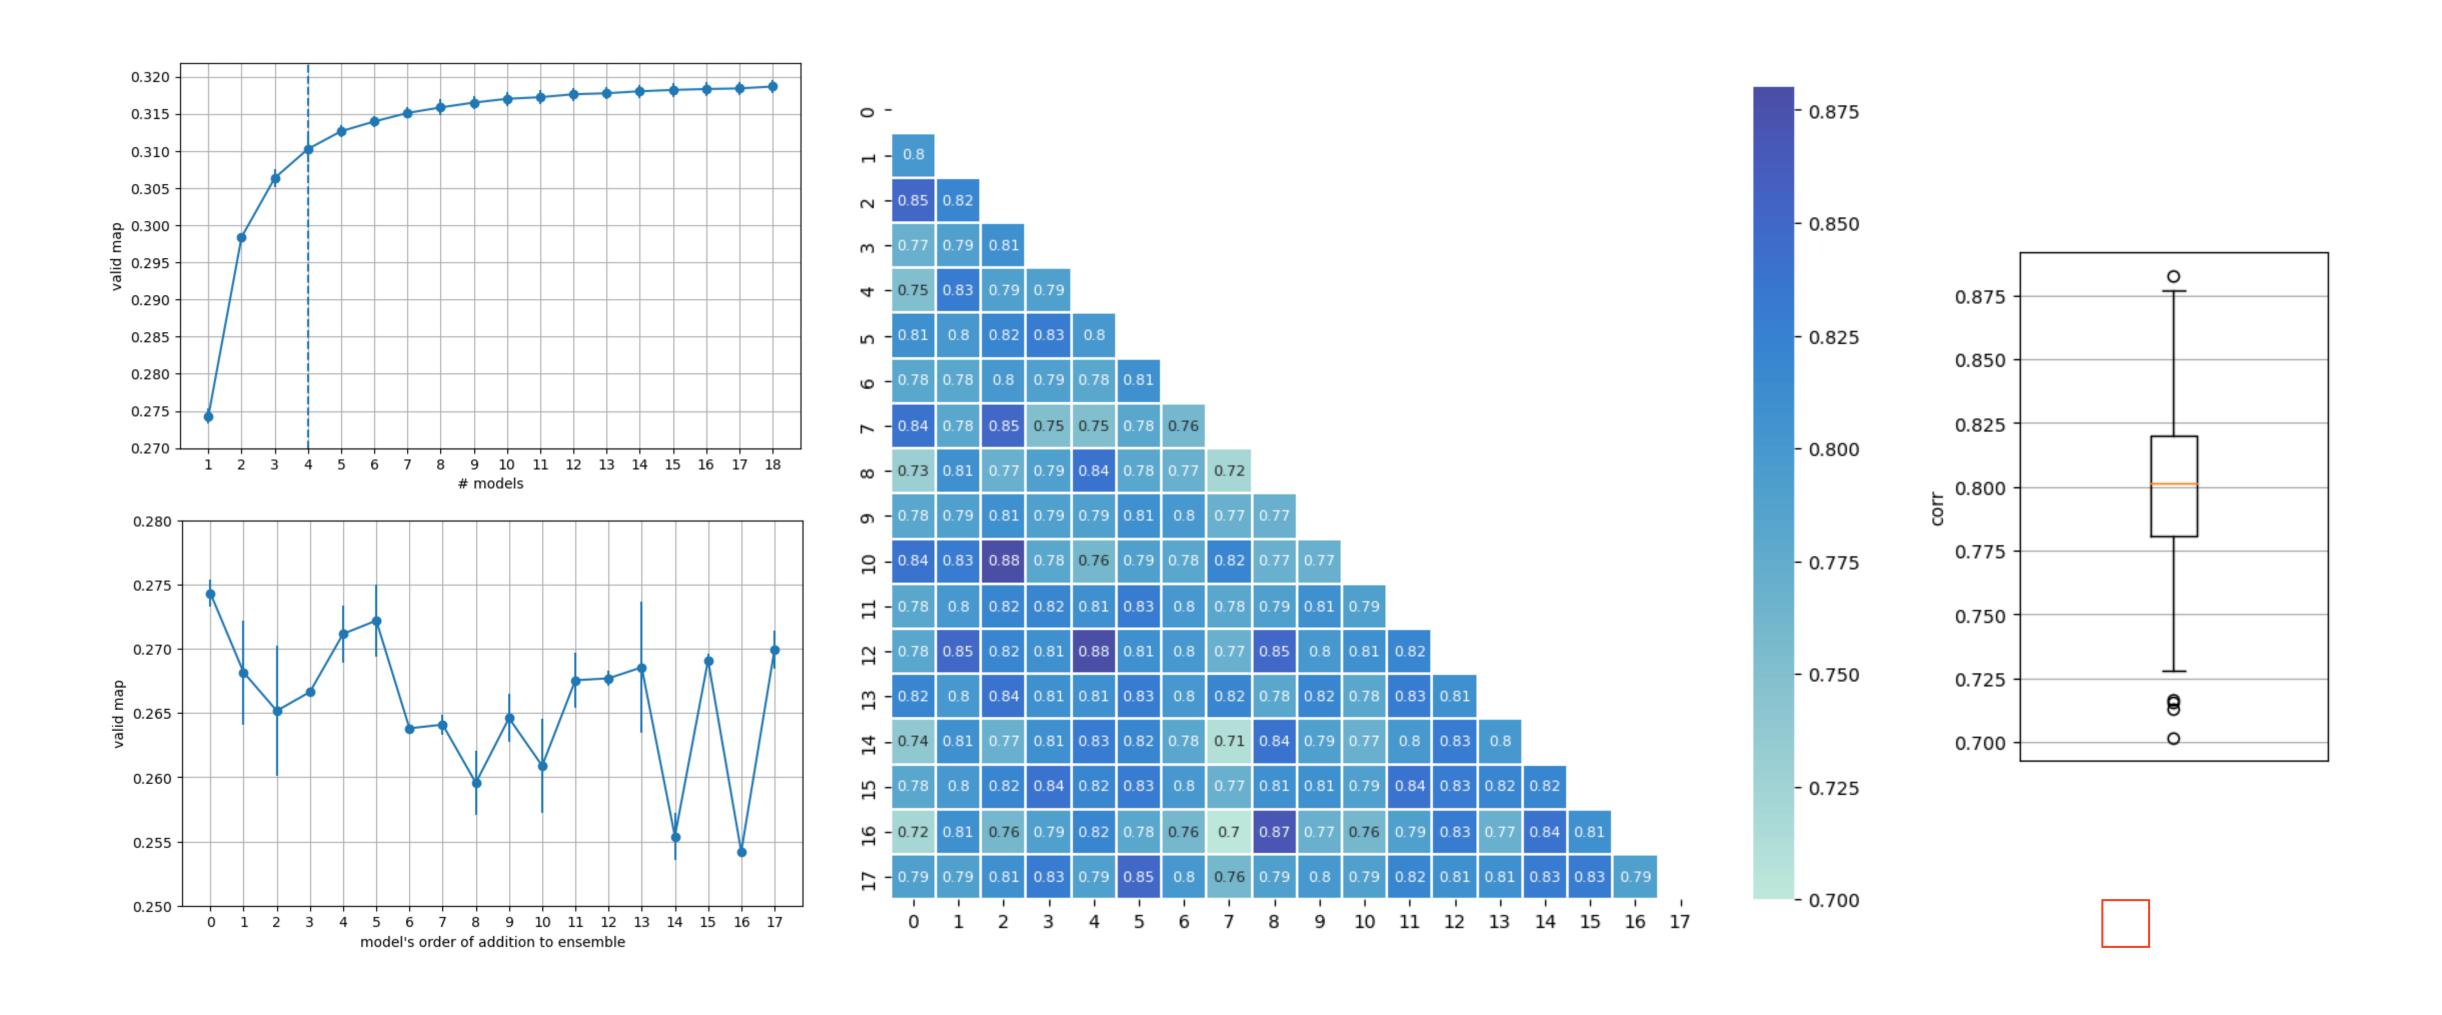


Построение ансамбля: шаг 4

method	# models	map
all	48	0.3163
greedy	35	0.3175
beam search, w=1	16	0.3182
beam search, w=8	17	0.3185
beam search, w=8, weighting	18	0.3186



Построение ансамбля: итог



Краткая история сабмитов

version	# models	valid	public	diff	
5	10		0.2795	0.0000	Первые эксперименты с трансформерами
8	31		0.2862	0.0067	Просто усреднить все модели, которые были на тот момент с более-менее адекватным качеством
9	9		0.2940	0.0078	Первый отбор моделей
16	15		0.2994	0.0054	Ансамбль более чем наполовину стал состоять из conformer-ов
17	15	0.3114	0.3025	0.0031	+ второй фолд
26	14	0.3158	0.3061	0.0036	+ несколько итераций процесса построения ансамбля
27	14	0.3158	0.3068	0.0007	+ третий фолд
30	18	0.3186	0.3095	0.0027	+ ещё несколько итераций «процесса», beam search, взвешивания

Пробовал, но не зашло

- RNN
- Трансформеры
- Постпроцессинг с учётом иерархии классов
- MoE, hyperopt

Спасибо за внимание